

¿Seguimos hablando entre humanos? Cuando la IA habla por ti

Propuesta de Diseño Experimental

Autor: Ing. Analucía Ramírez Magallanes

Maestría en Inteligencia Artificial

Universidad Internacional de La Rioja (UNIR)

Investigación en Inteligencia Artificial

1. Introducción y Motivación

A lo largo de la historia, las herramientas creadas por el ser humano han extendido principalmente sus capacidades físicas: el automóvil amplió la movilidad, la calculadora agilizó el cómputo, el teléfono extendió la comunicación a distancia. Sin embargo, la inteligencia artificial (IA) generativa representa una ruptura cualitativamente distinta: es la primera tecnología masiva que comienza a extender —y potencialmente a sustituir— capacidades internas del ser humano: el razonamiento, la reflexión, la estructuración emocional y la construcción de identidad. Por primera vez, una tecnología de uso masivo interviene en procesos considerados exclusivamente humanos, como la expresión emocional y la comunicación interpersonal. Millones de personas ya utilizan sistemas de IA para redactar mensajes de apoyo, felicitaciones y conversaciones cotidianas.

Este fenómeno ha alcanzado un umbral crítico. Jones et al. (2025) documentaron en un experimento controlado que GPT-4.5, configurado con una persona humanizada, fue identificado como humano el 73% de las veces por los jueces, superando incluso a participantes humanos reales (*Proceedings of the National Academy of Sciences*). Esto significa que la distinción perceptual entre comunicación humana y generada por máquina ya no puede darse por garantizada.

Sin embargo, la fluidez técnica no equivale a autenticidad percibida. Dorigoni y Giardino (2025) demostraron que cuando se revela que un mensaje fue generado por ChatGPT, la percepción de autenticidad y respeto moral cae significativamente, incluso cuando el contenido es idéntico al de un mensaje humano, y que este efecto se acentúa en contextos emocionalmente significativos como mensajes de apoyo o celebración (*Frontiers in Psychology*, DOI: 10.3389/fpsyg.2025.1568911).

A nivel técnico, el problema de distinción permanece abierto. Fariello et al. (2025) concluyen en su revisión sistemática que la proliferación de textos híbridos —escritos por humanos y editados por IA— y la mejora continua de los modelos generativos hacen que la detección automatizada sea aún insuficiente (*IJIMAI*, DOI: 10.9781/ijimai.2024.12.002). El *Counter Turing Test* de 2026 confirma que incluso sistemas de detección especializados fallan ante modelos como GPT-4, Claude 3.5 y Llama (*arXiv*: 2605.20761).

A pesar de esta evidencia, existe un vacío notable: la mayoría de los estudios se centran en detección técnica o en contextos angloparlantes, sin explorar cómo la población hispanohablante percibe la autenticidad de mensajes asistidos por IA en situaciones cotidianas. El presente estudio busca contribuir a cerrar ese vacío.

Detrás de esta encrucijada técnica late el riesgo de una **atrofia cognitiva por delegación**. La escritura no es un mero acto mecánico de codificación de caracteres; constituye un proceso neuropsicológico complejo que fomenta el pensamiento crítico, la estructuración de ideas abstractas y la autorregulación emocional. Cuando un individuo delega sistemáticamente la tarea de "pensar, estructurar y disculparse" a un algoritmo, el "músculo" cognitivo responsable de la resolución de conflictos interpersonales y de la introspección corre el riesgo de debilitarse por desuso. Las interacciones humanas se fundamentan en un pacto implícito de honestidad intelectual y esfuerzo expresivo. La automatización masiva de la empatía amenaza con vaciar de esencia los canales comunicativos, convirtiendo las relaciones en un intercambio de plantillas optimizadas donde ya nada se siente verdaderamente real. Por ende, resulta imperativo investigar el espectro real de la co-

creación (humano-IA) para determinar si la intervención tecnológica altera la percepción del receptor en nuestro entorno cultural.

2. Planteamiento de la Hipótesis

Para evaluar científicamente el impacto del grado de intervención de la Inteligencia Artificial en la comunicación interpersonal en español, el experimento se estructurará en torno a un modelo de tres niveles de gradación expresiva:

- **Condición 1 (Control Humano):** Mensajes generados con 100% de autoría humana, sin asistencia digital.
- **Condición 2 (Híbrida / Co-creación):** Mensajes co-creados en una proporción aproximada de 50% Humano y 50% IA (donde el humano redacta un borrador con la carga semántica original y la IA pule, refina y optimiza el tono y la estructura).
- **Condición 3 (Control IA):** Mensajes generados al 100% por un modelo de lenguaje a partir de un *prompt* o instrucción descriptiva básica del escenario.

A partir de este diseño, se formulan las siguientes hipótesis de investigación:

- **Hipótesis Alternativa (H_1):** Los mensajes híbridos (50% Humano / 50% IA) obtendrán puntuaciones de claridad y empatía significativamente más altas que los mensajes 100% IA, logrando niveles de percepción de autenticidad y confianza estadísticamente equivalentes a los de los mensajes 100% humanos en la población evaluada.
- **Hipótesis Nula (H_0):** No existirán diferencias estadísticamente significativas en la percepción de claridad, empatía, autenticidad o confianza por parte del receptor, independientemente del nivel de intervención de la Inteligencia Artificial en la redacción del mensaje.

3. Metodología y Configuración del Experimento

Para garantizar la reproducibilidad, el rigor científico y la completa eliminación de sesgos de confirmación, se propone un **diseño experimental factorial inter-sujetos mediante una prueba a ciegas (Blind Test)**. El experimento no requiere ejecución física, permaneciendo en su etapa de planificación y descripción metodológica formal.

A. Población y Muestreo

La justificación metodológica de este experimento radica en un control estricto de la representatividad social. La forma en que se estructuran los mensajes y la forma en que se interpretan está ligada intrínsecamente al capital cultural de los individuos. Por tanto, se implementará un muestreo aleatorio estratificado balanceado tanto en la fase de emisión como en la de recepción, abarcando un espectro educativo que va desde personas sin estudios formales hasta perfiles con doctorado.

1. **Grupo Emisor (N = 60):** Encargados de la producción de los estímulos textuales. Para neutralizar el sesgo de habilidad literaria base, las tres condiciones de estudio (100% Humano, 50/50 Híbrido, 100% IA) contarán con una distribución idéntica de perfiles académicos. Se seleccionarán 20 emisores por condición, subdivididos en:

- *Estrato E1 (n = 5):* Sin estudios formales o educación básica concluida.
- *Estrato E2 (n = 5):* Educación media superior o técnica.
- *Estrato E3 (n = 5):* Educación superior / Graduados universitarios.
- *Estrato E4 (n = 5):* Posgrado (Maestría o Doctorado).
- *Justificación de la diversidad en emisores:* Esto nos permite documentar cómo la IA nivela o altera la escritura en diferentes contextos. ¿Funciona la IA como un ecualizador social que dota de sofisticación lingüística a un emisor sin estudios formales, o despoja de tecnicismos y estilo propio a un emisor con doctorado?

2. **Grupo Receptor / Evaluador (N = 400):** Usuarios encargados de evaluar de forma ciega los estímulos textuales generados. Para garantizar que las métricas de percepción no estén sesgadas, se controlarán tres ejes demográficos:

- **Género:** 50% hombres y 50% mujeres (para evitar sesgos en la interpretación de la empatía emocional).
- **Distribución Etaria:** Tres estratos equitativos: 18-30 años (33.3%), 31-45 años (33.3%) y mayores de 46 años (33.3%) (para equilibrar los niveles de adopción tecnológica).
- **Trayectoria Académica:** Se estructurarán cuatro estratos proporcionales de 100 personas cada uno, replicando exactamente las clasificaciones de los emisores (desde personas sin estudios hasta posgraduados).
- *Justificación de la diversidad en receptores:* Los receptores con alta escolarización poseen herramientas analíticas complejas que facilitan la identificación de anomalías sintácticas o patrones repetitivos de los LLMs. Por el contrario, los sectores con menor instrucción formal evalúan el mensaje basándose estrictamente en su claridad o utilidad inmediata. Cruzar el nivel académico de quien escribe con el de quien lee permite descubrir si el "engaño" o la "deshumanización" de la IA es un fenómeno transversal o si está condicionado por el nivel educativo.

B. Procedimiento y Preparación de Datos

El desarrollo de la fase experimental simulada se desglosa en los siguientes pasos procedimentales estrictos:

1. **Estandarización del Escenario:** Se diseñará un caso de alta sensibilidad comunicativa y carga empática en el contexto hispanohablante: *Un mensaje de retroalimentación profesional y disculpa formal enviado por un supervisor a su equipo tras un periodo de alta tensión laboral por errores operativos.*
2. **Fase de Producción de Estímulos:**

- Los emisores de la Condición 1 redactarán el texto utilizando exclusivamente sus habilidades de comunicación escrita.
- Los emisores de la Condición 2 redactarán un boceto con sus ideas principales y utilizarán un prompt estandarizado (*"Optimiza la redacción y la estructura de este borrador para que suene profesional y empático en español, manteniendo la esencia del mensaje"*) en un LLM de acceso público (ej. ChatGPT o Claude).
- Los emisores de la Condición 3 únicamente introducirán la descripción del escenario en el LLM empleando el prompt (*"Redacta un mensaje de retroalimentación y disculpa profesional basado en la siguiente situación..."*), copiando el resultado de la IA de forma íntegra.

3. **Fase de Evaluación (Prueba a Ciegas):** Los 400 evaluadores serán asignados aleatoriamente a los estímulos generados por su correspondiente o cruzada categoría académica. **Factor crucial para evitar sesgos:** Se ocultará por completo a los evaluadores el verdadero propósito del experimento y el origen del texto (no sabrán si fue escrito por un humano o una máquina); se les informará que forman parte de un estudio sobre "estilos de comunicación institucional".

Tras la lectura del mensaje, cada participante del Grupo Receptor completará un cuestionario psicométrico digital cerrado utilizando una Escala Likert de 7 puntos (donde 1 es "Totalmente en desacuerdo" y 7 es "Totalmente de acuerdo"). Las variables a medir serán:

- **Variable Independiente:** Grado de intervención de la Inteligencia Artificial (Tres niveles: 100% Humano, 50% Híbrido, 100% IA).
- **Variables Dependientes (Métricas de Percepción):**
 - **Claridad Percibida:** ¿El mensaje es fácil de entender? (Evaluación de la coherencia, legibilidad y estructura lógica del texto).

- ***Empatía Percibida:*** ¿Se siente genuina la preocupación del emisor? (Grado en que el receptor percibe una consideración humana real y calidez en el trato).
- ***Sospecha de IA / Artificialidad:*** ¿Qué tan probable crees que es que este mensaje lo haya escrito una máquina? (Métrica de detección intuitiva que evalúa si el texto presenta estructuras rígidas o clichés automatizados).
- ***Confianza Interpersonal Relacional:*** Si descubriera que este mensaje fue editado o generado por una IA, ¿cambiaría su nivel de confianza hacia esa persona en el futuro? (Evaluación del impacto a largo plazo de la automatización en el pacto de honestidad de la comunicación).
- **Fase Cualitativa Complementaria (Preguntas Abiertas):**

Con el propósito de enriquecer los hallazgos cuantitativos y profundizar en los mecanismos cognitivos detrás de la percepción del receptor, el cuestionario cerrará con una fase cualitativa corta compuesta por dos preguntas abiertas de respuesta libre. Esta aproximación de métodos mixtos permitirá comprender las causas subyacentes de la confianza o el escepticismo, permitiendo a los evaluadores identificar los marcadores textuales específicos que detonaron sus juicios. Las interrogantes planteadas serán:

1. *Si en la pregunta anterior indicaste que existe probabilidad de que el mensaje haya sido escrito por una máquina, ¿qué elementos específicos del texto (vocabulario, tono, estructura, repeticiones) te hicieron sospechar?*
2. *¿Qué características del mensaje te transmitieron mayor o menor calidez y honestidad por parte de la persona que te lo envió?*

4. Comparación con Otros Estudios y Plan de Validación Estadístico

A diferencia de las investigaciones clásicas de detección técnica (como las revisadas por Fariello et al., 2025) o las pruebas de Turing tradicionales orientadas al entorno anglosajón, este diseño experimental innova al desplazar el foco hacia el impacto cualitativo en la población hispanohablante, analizando cómo el uso híbrido (humano-IA) puede mitigar la

pérdida de respeto moral detectada por Dorigoni y Giardino (2025) cuando las máquinas operan en solitario.

Para refutar o no la hipótesis nula (H_0), los datos recopilados a través de las escalas Likert serán sometidos a un análisis de varianza paramétrico (**ANOVA de una vía**). Este análisis permitirá comparar si las diferencias entre las medias de las puntuaciones de claridad, empatía y confianza de los tres grupos independientes son estadísticamente significativas ($p < 0.05$). Adicionalmente, se realizarán pruebas de contraste *post-hoc* (como la prueba de Tukey) para determinar exactamente entre qué pares de condiciones residen las discrepancias perceptivas. El cruce de datos bidireccional (Nivel Educativo del Emisor $\times$ Nivel Educativo del Receptor) mediante un ANOVA de dos vías permitirá identificar si la asimetría académica actúa como una variable moderadora en la detección y sospecha de la intervención algorítmica.

5. Justificación de la Hipótesis y las Deducciones de la Investigación

La premisa de que el modelo híbrido (H_1) superará al texto algorítmico y mantendrá niveles de confianza similares al humano se fundamenta en los mecanismos de la co-creación aumentada. La fluidez sintáctica de los LLMs contemporáneos estandariza positivamente variables técnicas de legibilidad y cohesión formal. Esta optimización es especialmente significativa en los estratos de emisores con menor escolaridad formal, ya que actúa como un ecualizador que remueve barreras lingüísticas. Sin embargo, dado que los modelos carecen de intencionalidad situacional, la intervención humana al 50% es el componente crítico que inyecta la carga semántica original y el contexto adaptado a la realidad del emisor. Al fusionar la estructura matemática de la máquina con la dirección consciente del individuo, el mensaje elude el "valle inquietante" de la automatización absoluta que suele activar el rechazo del receptor.

Bajo este enfoque, las deducciones metodológicas de la investigación asumen que los fallos relacionales documentados en la literatura internacional no provienen de un rechazo sistemático hacia las tecnologías generativas, sino de la penalización moral ante el engaño percibido y la delegación total de la empatía. Al evaluar de forma cruzada diversas trayectorias académicas, el diseño permite deducir si la sofisticación lingüística de la IA es percibida de igual manera por un doctor que por un ciudadano sin estudios básicos. Si los datos finales validan la hipótesis, se demostrará empíricamente que la preservación del esfuerzo cognitivo del emisor es el único filtro capaz de sostener la veracidad y la confianza en la interacción humana.

6. Consideraciones Finales e Impacto Esperado

A pesar de las limitaciones inherentes a un diseño que permanece en una fase de planificación teórica, la estructura metodológica propuesta aporta un marco interpretativo de alto valor para la psicología de la comunicación mediada por tecnología. Su principal innovación radica en desplazar el análisis desde la simple capacidad técnica de engaño (Prueba de Turing tradicional) hacia la evaluación cualitativa del vínculo interpersonal resultante, promoviendo un enfoque de diseño centrado firmemente en el bienestar y la honestidad hacia el usuario.

Se anticipa que los hallazgos derivados de este experimento permitirán trazar directrices éticas y funcionales robustas para el desarrollo y adopción de herramientas de asistencia a la redacción. Al validar el espectro de la co-creación, la investigación evita caer en posturas tecnofóbicas o tecnofílicas acríticas. En su lugar, propone concebir a la Inteligencia Artificial no como un sustituto del pensamiento, sino como un andamiaje técnico que potencia la claridad del lenguaje sin secuestrar la identidad ni mecanizar el afecto, salvaguardando así la autenticidad y los pactos implícitos de la comunicación en el entorno cultural hispanohablante.

7. Problema Real que Resuelve la Investigación (Impacto y Financiación)

Esta investigación resuelve un problema crítico de gobernanza digital, salud cognitiva y optimización organizacional, ofreciendo un valor estratégico claro para captar inversión pública y privada:

- **Para el Sector Gubernamental / Fondos de Innovación Pública (Ej. CONAHCYT / Ministerios de Educación y Tecnología):** El proyecto aborda un problema de bienestar social y salud pública: el riesgo de la **atrofia cognitiva poblacional** y la erosión de la cohesión social debida a la homogeneización algorítmica de la comunicación. Al aportar datos específicos de la población hispanohablante con diversas trayectorias académicas (tanto de quienes escriben como de quienes leen), la investigación dota al gobierno de la evidencia científica necesaria para diseñar políticas públicas de alfabetización digital y marcos regulatorios de educación que prevengan la pérdida de capacidades críticas de lectoescritura en las nuevas generaciones. Resuelve la falta de lineamientos oficiales sobre el uso ético y cognitivamente seguro de la IA en instituciones del Estado y escuelas públicas, asegurando que la tecnología sea un puente de inclusión y no una barrera que acentúe las brechas educativas.
- **Para el Sector Privado / Empresas Tecnológicas y Corporativos:** El estudio resuelve un problema financiero de **pérdida de capital reputacional y confianza del cliente**. Las empresas están automatizando masivamente la atención al cliente y la comunicación interna para reducir costos, pero lo hacen a ciegas, arriesgándose a destruir la lealtad de la marca si los usuarios perciben los mensajes como deshumanizados (efecto documentado por Dorigoni y Giardino, 2025). Esta investigación proporciona a las empresas la "fórmula exacta de equilibrio" (el porcentaje óptimo de hibridación humano-IA) para implementar asistentes de escritura o *chatbots* que aumenten la productividad operativa sin sacrificar la confianza del consumidor ni la moral de los empleados, adaptándose al nivel cultural de sus clientes. Invierte en este estudio el corporativo que busca validar

científicamente sus herramientas antes de que el rechazo del mercado genere pérdidas multimillonarias.

Referencias Bibliográficas

- Roy, R., Singh, G., Aziz, A. et al. (2026). *Findings of the Counter Turing Test: AI-Generated Text Detection*. arXiv:2605.20761v1. <https://arxiv.org/html/2605.20761v1>
- Dorigoni, A. & Giardino, P. L. (2025). The illusion of empathy: evaluating AI-generated outputs in moments that matter. *Frontiers in Psychology*, 16, Art. 1568911. <https://doi.org/10.3389/fpsyg.2025.1568911>
- Fariello, S., Fenza, G., Forte, F., Gallo, M. & Marotta, M. (2025). Distinguishing Human From Machine: A Review of Advances and Challenges in AI-Generated Text Detection. *International Journal of Interactive Multimedia and Artificial Intelligence (IJIMAI)*, 9(3), 6-18. <https://revistas.unir.net/index.php/ijimai/article/view/234>
- Jones, C. R. & Bergen, B. K. (2025). Large language models pass the Turing test. *Proceedings of the National Academy of Sciences (PNAS)*, 122. <https://doi.org/10.1073/pnas.2524472123>
- La Vanguardia. (16 de abril de 2025). *La IA ya pasa el test de Turing: que no cunda el pánico (todavía)*. La Vanguardia Tendencias. <https://www.lavanguardia.com/vida/20250416/10590156/ia-pasa-test-turing-corrán-todavía.html>
- Fernández-Hernández, A., Arboledas-Márquez, J. L., Ariza-Merino, J. & Jiménez-Zafra, S. M. (2023). *Taming the Turing Test: Exploring Machine Learning Approaches to Discriminate Human vs. AI-Generated Texts*. En IberLEF 2023: AuTextification Shared Task. CEUR Workshop Proceedings, Vol. 3496. <https://ceur-ws.org/Vol-3496/autextification-paper12.pdf>